에어비앤비체 해독기 작업 계획표

작업을 세 파트로 나누어 순서대로 진행한다. 담당 칸은 팀에서 채운다.

가장 먼저 할 것: Part 1의 확인 작업 4가지. 이 결과에 따라 데이터 생성 방식과 모델이 정해진다.

Part 1. 확인 작업

할 일	확인 방법	결과에 따라	담당
KOTOX 규칙 코드 확인	저장소에서 원하는 문장을 넣어 난독문을 만드는 코드가 있는지 확인	있으면 에어비앤비체 규칙만 골라 사용, 없으면 논문 규칙을 보고 파이썬으로 직접 구현	
갓종대왕 저장소 확인	github.com/thtl1999/God-sejong 접속, 규칙 코드와 라이선스 확인	특징 참고용으로 사용	
기존 교정 모델 실행	Colab에서 `Soyoung97/gec_kr`를 불러와 "환장실이 넘무 작아욤" 등 입력	실패 결과를 캡처해 발표 자료에 넣음 (기능 추가의 근거)	
KoBART 토크나이저 확인	난독문 몇 개를 토큰화해 `<unk>`가 많이 나오는지 확인	많으면 pko-t5로 교체 검토, 결과 화면은 발표 자료에 넣음	

원본 저장소는 CUDA 호환 문제와 유지보수 중단을 안내하고 있으므로, 실행이 막히면 저장소 코드 대신 Hugging Face `transformers`로 모델만 불러와 테스트한다.

구현 시 주의사항:

예상 한계	대응
KoBART 토크나이저가 처음 보는 글자를 `<unk>`로 처리할 가능성	구현 초반에 확인, 문제 시 pko-t5(BBPE, 미등록 글자 없음)로 교체
난독화 데이터만 학습하면 기존 교정 능력이 약해질 가능성 (망각 현상)	기존 교정 데이터를 일부 섞어 학습하고, 학습 전후 교정 결과 확인

Part 2. 데이터 구축

할 일	산출물	담당
난독화 규칙 구현 (받침 추가, 받침 중복, 연음, 된소리, 비슷한 발음 바꾸기)	규칙 코드	
NSMC 전처리 (빈 문장·중복 제거), 원문 기준으로 학습/검증/평가 분할	원문 데이터	
규칙 적용해 (난독문, 원문) 쌍 생성	학습 데이터	
평가 데이터 B: airbnbfy로 난독문 30~50개 생성	평가 데이터 B	
평가 데이터 C: 팀원 각자 에어비앤비체 문장 10~15개와 원문 작성 (숙소 후기 문장 포함)	평가 데이터 C	전원

Part 3. 모델 학습, 평가, 데모

할 일	산출물	담당
1만 쌍으로 짧게 시험 학습 (10~20분), 체크포인트를 드라이브에 저장	학습 코드 동작 확인	
전체 데이터로 학습 (교정 데이터 일부 섞기)	학습된 모델	
평가: 완전 일치율, CER, 의미 보존 (부정 표현·숫자 유지 여부)	결과 표	
기존 모델 vs 학습 모델 비교, 틀린 사례 분석	오류 분석	
데모 화면 (난독문 입력 → 복원 결과)	데모	

역할 분담 예시

역할	맡는 일
데이터	KOTOX 규칙 확인과 구현, NSMC 전처리, 학습 데이터 생성
모델	기존 모델 실행, 토크나이저 확인, 학습 코드 수정과 학습
평가·데모	평가 데이터 B·C 수집, 평가 코드, 데모 화면

평가 데이터 C(직접 쓴 에어비앤비체)는 역할과 상관없이 모든 팀원이 나눠서 쓴다.