에어비앤비체 해독기

KoBART 기반 한국어 문법 교정 모델에 난독화 복원 기능 추가

팀명 _____ **발표일** 2026년 10월 13일

팀원 _____

과제 요구사항 대응표

과제 요구사항	문서 위치	핵심 내용
1. 발표 주제 설명 (문제 정의)	1장	에어비앤비체 정의·특징, 문제 상황, 선행 연구(2025–2026), 프로젝트 목표
2. 사용할 데이터셋 조사	2장	NSMC 원문 + KOTOX 변환 규칙 기반 (난독문, 원문) 쌍 생성, 평가 데이터 A·B·C
3. 참조할 코드 조사 및 분석	3.1절	Standard_Korean_GEC (ACL 2023, KoBART 기반 교정)
3. 사용한 NLP 모델의 원리 분석	3.2–3.3절	KoBART 구조, Text Infilling 사전학습, 선택 근거
4. 구현하고자 하는 구체적인 내용	4–5장	기존 “문법 교정”에 “난독화 복원”을 추가, 평가 계획
제출물 2) Data Set · Code · NLP 원리	6장	제출물 요약 및 GitHub 링크

1. 발표 주제 및 문제 정의

요구사항 ①

1.1 에어비앤비체란?

- 번역을 어렵게 만들기 위해 자음·모음·받침 등을 의도적으로 변형한 한국어 표현
- 한국어 사용자는 발음과 문맥을 통해 원래 뜻을 추측할 수 있음
- 변형이 심하면 사람도 읽기 어렵고, 자동 번역·검색에도 활용하기 어려움
- 숙소 후기에서는 호스트에게 부정적 내용이 전달되는 것을 피하려는 의도로 글자를 변형하는 경우가 있음

1.2 에어비앤비체의 특징

공식적으로 정해진 규칙은 없으나, 에어비앤비체 변환 사이트(갓종대왕 번역기, airbnbfy)가 사람들이 쓰던 방식을 규칙으로 정리해 두었다. 두 사이트의 옵션을 합치면 다음과 같다.

특징	설명	예시
받침 추가	받침 없는 글자에 의미 없는 받침을 붙임	너무 → 넘무
받침 중복	뒷글자 첫 자음을 앞글자 받침으로 한 번 더 씀	화장실 → 홪장실
연음	받침을 뒷글자로 넘겨 소리 나는 대로 씀	작아요 → 자가요
된소리 (쉬프트키)	자음을 된소리로 바꿈	번역 → 뻔역
비슷한 발음으로 바꾸기	발음이 비슷한 자모로 교체	좋아요 → 조아욤
야민정음	모양이 비슷한 글자로 교체	명작 → 띵작
순서 섞기	단어 안 글자 순서를 바꿈	캠브릿지 → 캠릿브지
단어 추가	앞뒤로 칭찬이나 관계없는 말을 붙여 번역 결과를 흐림	(앞) 정말 좋았어요! …

※ 예시는 설명을 위해 만든 것. 사용 방식으로는 “별점 만점 + 앞부분 빈말 칭찬 + 진짜 불만은 비틀어 쓰기” 구조가 흔하다.

1.3 문제 상황

- 숙소의 불편 사항을 공유하는 후기에도 난독화된 표현이 등장
- 읽는 사람은 글자마다 원래 표현을 추측해야 함
- 기존 한국어 문법 교정기는 맞춤법·띄어쓰기 같은 **“실수”**를 고치도록 만들어져, **“일부러 비튼”** 난독문은 처리 범위 밖임 (발표 전 기존 모델로 직접 확인)

구분	예시
난독화 문장	홤장실이 넘무 작아욤
복원 목표	화장실이 너무 작아요

※ 설명을 위해 만든 예시

1.4 선행 연구 및 최근 사례

시기	사례	프로젝트에 활용할 근거
2025.05.27	**PHISH in MESH** 연구: 한국어의 발음이 비슷한 글자로 바꾸어 혐오 표현 탐지를 우회하는 문제와, 음운 정보를 활용한 대응 방법을 연구	한글 변형은 실제 NLP 모델의 처리 성능과 연결되는 연구 문제라는 근거
2025.10.13 최초 공개 → 2026.08.04 개정	**KOTOX** 연구: 난독화된 한국어의 복원과 유해 표현 순화를 위한 데이터셋·변환 규칙 공개 (코드·데이터 GitHub 공개)	‘난독문 → 정상 문장’ 복원이 2025~2026년에도 연구되고 있다는 직접적인 근거이자, **이번 프로젝트의 데이터 생성 규칙 출처**
2026.07	국립민속박물관 공식 전시 소개: ‘암호 해독실’에서 에어비앤비체를 현대 한글 암호화 사례로 영상 소개	에어비앤비체가 최근에도 소개되는 한글 활용 현상이라는 근거

출처: arXiv:2505.21380 (PHISH in MESH) · arXiv:2510.10961 (KOTOX) · 국립민속박물관 공식 자료

1.5 프로젝트 목표

> **난독화된 후기의 의미와 부정적 평가를 유지하면서, 읽기 쉬운 한국어 문장으로 복원한다.**

- 의도적으로 변형한 한국어를 읽기 쉬운 문장으로 복원

- 기존 문법 교정 모델과 추가 학습한 모델의 복원 성능 비교

2. 사용할 데이터셋과 구성 방법

요구사항 ②

2.1 데이터 확보 방향

- 혐오 표현 분야에는 난독화 병렬 데이터(KOTOX)가 공개되어 있으나, 숙소 후기처럼 **일반 문장을 대상으로 한 에어비앤비체 병렬 데이터셋은 없음**
- 따라서 KOTOX의 변환 규칙을 참고하여 일반 리뷰 문장(NSMC)에 적용해 (난독문, 원문) 쌍을 직접 생성
- 별도의 라벨링 작업 없이 수만 쌍을 확보할 수 있다는 점이 이 주제의 장점

2.2 주요 원문 데이터: NSMC (Naver Sentiment Movie Corpus)

- 네이버 영화 리뷰로 구성한 한국어 감성 분석 데이터셋
- 학습용 15만 개, 평가용 5만 개의 리뷰 제공
- 짧은 후기 문장이 많고, 후기 문체라 에어비앤비체와 분위기가 비슷해 난독화 복원용 데이터 생성에 활용
- 이번 프로젝트에서는 긍정·부정 라벨보다 리뷰 문장 자체를 사용

출처: github.com/e9t/nsmc

2.3 데이터셋 구성

용도	데이터	비고
원문 코퍼스	NSMC 네이버 영화 리뷰 등 한국어 리뷰 문장	후기 문체라 에어비앤비체와 분위기가 비슷함
학습 데이터	원문 + KOTOX 변환 규칙 중 에어비앤비체에 해당하는 규칙(또는 직접 구현한 규칙)으로 생성한 난독문	자동 생성, 수만 쌍
평가 데이터 A	학습에 쓰지 않은 원문으로 같은 규칙을 적용해 생성한 문장	학습한 규칙에 대한 성능
평가 데이터 B	airbnbfy 한글 난독화로 만든 문장 수십 개	다른 생성기 방식에도 통하는지 확인
평가 데이터 C	실제 사람이 쓴 에어비앤비체 수십 개 (팀원 직접 작성·수집, 숙소 후기 문장 포함)	실제 상황 성능

2.4 난독화 데이터 생성 도구

자료	역할	내용
KOTOX	학습 데이터 생성 (주 도구)	한국어 난독화 패턴을 언어학적으로 분류하고 실제 사례에서 뽑은 변환 규칙. 코드·데이터 GitHub 공개 (MIT). 혐오 표현용 규칙도 섞여 있으므로 **1.2절 특징에 해당하는 규칙만 골라 사용**
갓종대왕 번역기	에어비앤비체 특징 참고	받침 넣기, 쉬프트키 누르기, 야민정음, 캠브리지 연구 효과, 관계없는 단어 추가, 앞뒤 칭찬 추가 규칙 제공 (에어비앤비체 전용 변환기, GitHub Pages로 배포)
airbnbfy	평가 데이터 B 생성	학습 규칙과 다른 방식의 난독문을 만들어 일반화 성능 검증 (소스 비공개 React 웹앱)

KOTOX 저장소에 원하는 문장에 규칙을 적용하는 코드가 없거나 수정하기 어려우면, 논문의 규칙을 참고해 한글 유니코드 조합 공식으로 파이썬으로 직접 구현한다.

글자 코드 = 0xAC00 + (초성 × 21 + 중성) × 28 + 종성

예: “가”를 초성·중성·종성으로 분해한 뒤 종성 자리에 ㄱ을 넣고 다시 조합하면 “각”이 된다.

2.5 학습 데이터 구성 절차

단계	작업
원문 선별	빈 문장·중복 제거, 원래부터 심하게 깨진 문장 제외
데이터 분할	원문 기준으로 학습·검증·평가 데이터 분리
난독화 생성	KOTOX 규칙 중 에어비앤비체 해당 규칙(받침 추가, 받침 중복, 연음, 된소리, 비슷한 발음 바꾸기 등) 적용
정답 구성	변형 전 문장을 복원 정답으로 사용

2.6 난독화 규칙 적용 범위

단계	규칙	이유
우선 적용	받침 추가, 받침 중복, 연음, 된소리, 비슷한 발음 바꾸기, 야민정음 등 글자 변형	글자 단위 복원으로 해결 가능, 난이도 낮음
확장 과제	관계없는 단어 추가, 앞뒤 칭찬 추가 등 단어 추가·삭제	복원이 아니라 삭제 판단이 필요해 난이도 높음

2.7 학습 데이터 예시

입력 문장 (난독화)	정답 문장 (원문)
연끼가 넘무 조아욤	연기가 너무 좋아요
내용이 넘무 지루햇어욤	내용이 너무 지루했어요

※ 직접 만든 예시이며, 실제 NSMC 인용문은 아님

2.8 보완할 점

- 영화 리뷰와 숙소 후기는 사용하는 단어가 다름 → 숙소 관련 문장을 평가 데이터 C에 포함
- 규칙으로 만든 문장과 사람이 쓴 문장은 차이가 있음 → 평가 데이터 B·C로 별도 확인
- 같은 원문의 변형 문장들이 학습·평가 양쪽에 섞이지 않도록 관리

3. 참조 코드 및 NLP 모델 분석

요구사항 ③

3.1 참조 코드: Standard_Korean_GEC

- ACL 2023 한국어 문법 오류 교정 연구의 공식 저장소
- KoBART 기반 교정 모델과 학습·추론 코드 제공
- 공개 모델 `Soyoung97/gec_kr` 를 기존 교정기의 기준선(baseline)으로 사용

출처: github.com/soyoung97/Standard_Korean_GEC

코드에서 확인한 처리 방식

코드	기존 역할	프로젝트에서 활용할 부분
`dataset.py`	입력·정답 문장 쌍을 읽고 토큰화·길이 처리	난독문·원문 쌍을 학습 데이터로 입력
`model.py`	정답 문장에 대한 손실 계산, 출력 문장 생성	복원 모델 학습과 추론
`run.py`	모델·데이터 로딩, 학습 실행 및 체크포인트 설정	새 데이터 경로와 학습 설정 연결

데이터 코드는 탭으로 구분한 두 문장을 읽고, 모델 코드는 정답 토큰을 이용해 손실을 계산한 뒤 `generate()` 로 문장을 생성한다.

추가·수정할 부분

- 난독화 데이터 생성 코드 (KOTOX 규칙 기반)
- 학습 데이터와 모델 초기화 설정
- 복원 성능 평가 코드
- 난독문 입력 및 복원 결과 출력 화면(데모)

저장소는 현재 CUDA 환경에서의 호환성 문제와 기존 코드의 유지보수 중단을 안내하고 있다. 따라서 코드를 그대로 실행하기보다 **학습 구조를 참고하여 현재 실행 환경에 맞게 수정해 활용**할 계획이다. 실행이 막히면 Hugging Face `transformers` 로 모델만 불러와 사용한다.

3.2 사용할 NLP 모델: KoBART의 원리

기본 정보

- SK텔레콤이 공개한 한국어 BART 모델
- **문장을 다른 문장으로 바꿔 쓰는 데 특화된 한국어 언어모델** (인코더-디코더 계열: 번역·요약·교정에 사용)
- 약 1억 2,400만 개의 파라미터 (거대 언어모델에 비해 매우 작은 규모)
- 인코더 6층 · 디코더 6층의 문장 생성(sequence-to-sequence) 구조
- 40GB 이상의 한국어 텍스트로 사전학습

출처: github.com/SKT-AI/KoBART

문장을 처리하는 원리

구성	역할
토크나이저	입력 문장을 모델이 처리할 토큰으로 나눔
인코더	입력 전체의 문맥을 반영한 표현을 만듦
디코더	인코더의 정보와 앞서 생성한 토큰을 참고해 다음 토큰을 생성

사전학습 방식

- 문장의 일부 구간을 가리는 Text Infilling 방식 사용
- 손상된 입력을 보고 원문을 복원하도록 학습
- 추가 학습(fine-tuning)을 통해 특정 문장 생성 작업에 적용

이번 프로젝트의 추가 학습

- 입력: 난독화된 문장 / 정답: 변형 전 원문
- 정답 문장을 생성할 가능성이 높아지도록 모델의 가중치 조정
- KoBART는 에어비앤비체를 학습한 적이 없어 그대로는 읽지 못하므로, (난독문, 원문) 쌍으로 이 작업을 가르침

3.3 KoBART가 적합한 이유

선택 이유	프로젝트와의 연결
손상된 문장을 복원하는 사전학습	난독문 복원과 학습 목표가 유사함
문맥을 활용하는 인코더·디코더 구조	글자 하나의 치환을 넘어 문장 전체를 고려해 복원
한국어 중심 사전학습	한국어 표현과 문장 패턴을 활용할 수 있음
기존 KoBART 교정 코드 존재	데이터 처리·학습·추론 구조를 참고할 수 있음
거대 언어모델보다 작은 규모	Colab GPU에서 짧은 문장과 소규모 데이터부터 학습을 시도하기에 적합

※ Colab 학습 가능 범위는 GPU 메모리와 배치 크기 등에 따라 조정한다.

> **검증할 질문:** 일반 문법 교정 모델에 난독화 문장 쌍을 추가 학습하면, 에어비앤비체 복원 성능이 개선되는가?

※ 사전학습의 손상 방식(구간 마스킹)과 에어비앤비체의 변형 방식(자모 변형)은 다르므로, 실제 복원 능력은 실험으로 확인한다.

4. 구현하고자 하는 구체적인 내용

요구사항 ④

4.1 기존 구현 대비 추가 기능

구분	기존 구현 (Standard_Korean_GEC)	이번 프로젝트 (추가)
주요 기능	한국어 문법 오류 교정	**의도적인 한글 난독화 복원**
입력 예시	한국어는어렵다.	홤장실이 넘무 작아욤
출력 예시	한국어는 어렵다.	화장실이 너무 작아요
학습 데이터	오류 문장 · 교정 문장	난독화 문장 · 변형 전 원문

4.2 구현 범위

- 받침 추가·교체와 된소리화 등 글자 변형을 우선 처리
- 한 문장 안에 여러 변형이 섞인 경우까지 확장
- 입력 문장의 의미·감정·긍정 및 부정 표현 유지
- 난독문 입력창과 복원 결과를 보여주는 데모 구현

4.3 개발 순서

1. 기존 교정 모델(`gec_kr`)의 난독문 출력 확인, KoBART 토크나이저의 난독문 처리 확인
2. KOTOX 규칙으로 학습 데이터 생성
3. KoBART 기반 교정 모델에 추가 학습 (기존 교정 데이터 일부 포함)
4. 기존 모델과 복원 성능 비교
5. 사람이 작성한 난독문으로 데모 및 오류 분석

5. 평가 방법과 예상 한계

5.1 성능 비교

평가 항목	확인할 내용
기존 모델 vs 추가 학습 모델	난독화 복원 학습의 효과
학습과 같은 규칙으로 만든 문장 (평가 A)	학습한 변형 패턴의 복원 능력
다른 생성기(airbnbfy)로 만든 문장 (평가 B)	새로운 변형 방식에 대한 일반화
사람이 작성한 실제 난독문 (평가 C)	실제 표현에 대한 복원 능력

5.2 평가 지표

- **완전 일치율(Exact Match):** 출력이 정답 문장과 완전히 같은 비율
- **CER(Character Error Rate):** 정답 대비 글자의 삽입·삭제·치환 오류 정도
- **의미 보존 확인:** 부정 표현, 시설명, 숫자 등 핵심 정보의 유지 여부

5.3 예상 한계와 대응

예상 한계	대응
생성 규칙에만 익숙해질 가능성	실제 사람이 쓴 문장으로 별도 평가
원문을 여러 방식으로 추측할 수 있음	문자 지표와 의미 보존을 함께 확인
부정 표현을 바꾸거나 내용을 추가할 가능성	‘안’, ‘못’, 불편 사항 등의 오류를 별도 분석
영화 리뷰와 숙소 후기의 도메인 차이	숙소 관련 평가 문장 보완
KoBART 토크나이저가 처음 보는 글자를 `<unk>`(미등록 토큰)로 처리할 가능성	구현 초반에 난독문을 토큰화해 확인, 문제 시 pko-t5(BBPE 토크나이저, 미등록 글자 없음)로 교체
난독화 데이터만 학습하면 기존 교정 능력이 약해질 가능성 (망각 현상)	기존 교정 데이터를 일부 섞어 학습하고, 학습 전후 교정 결과 확인

> 기존 문법 교정 모델을 난독화 복원으로 확장하고, 실제 후기에서도 원래 의미를 유지하는지 검증한다.

6. 제출물 정리

제출물 2)

제출 항목	내용
조사한 Data Set	NSMC (네이버 영화 리뷰, 학습 15만 · 평가 5만) — 리뷰 문장을 원문으로 사용하고, KOTOX 변환 규칙 중 에어비앤비체 해당 규칙(또는 유니코드 조합 공식으로 직접 구현한 규칙)으로 (난독문, 원문) 쌍 생성. 평가 데이터 A(같은 규칙) · B(airbnbfy) · C(사람이 쓴 문장) 구성 (2장) https://github.com/e9t/nsmc · https://github.com/leeyejin1231/KOTOX · https://thtl1999.github.io/God-sejong · https://airbnbfy.hanmesoft.com/
참조할 Code	Standard_Korean_GEC (ACL 2023, KoBART 기반 한국어 문법 교정, 기준 모델 `Soyoung97/gec_kr`) https://github.com/soyoung97/Standard_Korean_GEC 팀 저장소:
사용한 NLP 모델의 원리	KoBART — 문장을 다른 문장으로 바꿔 쓰는 데 특화된 한국어 언어모델. 인코더 6층·디코더 6층 seq2seq, 약 1.24억 파라미터, Text Infilling(손상 문장 → 원문 복원) 사전학습. 난독문 → 원문 쌍으로 추가 학습하여 복원 작업에 적용 (3.2–3.3절) https://github.com/SKT-AI/KoBART

참고 자료

- KoBART 공식 저장소 — https://github.com/SKT-AI/KoBART
- Standard_Korean_GEC 공식 저장소 — https://github.com/soyoung97/Standard_Korean_GEC
- Standard_Korean_GEC dataset.py — https://github.com/soyoung97/Standard_Korean_GEC/blob/main/dataset.py
- NSMC 공식 저장소 — https://github.com/e9t/nsmc
- KOTOX 코드·데이터 — https://github.com/leeyejin1231/KOTOX
- pko-t5 (토크나이저 문제 시 대안) — https://github.com/paust-team/pko-t5
- 갓종대왕 번역기 — https://thtl1999.github.io/God-sejong
- airbnbfy 한글 난독화 — https://airbnbfy.hanmesoft.com/
- PHISH in MESH (2025) — https://arxiv.org/abs/2505.21380
- KOTOX (2025, 2026 개정) — https://arxiv.org/abs/2510.10961
- 국립민속박물관 '암호 해독실' 전시 소개 (2026.07) — https://www.nfm.go.kr (전시 소개 페이지 주소로 교체 필요)